

Taller Parcial 1 - Minería de Datos

Oscar David Pava Ariza

2026-05-8

1. Introducción

La revista seleccionada es **Frontiers in Plant Science** (ISSN: 1664-462X), una revista de acceso abierto clasificada como **Q1** en Plant Sciences según JCR 2024, con un factor de impacto de 4.8. Publica investigación en todas las áreas de la biología vegetal y cuenta con más de 3.200 artículos publicados en 2025.

URL base: <https://www.frontiersin.org/journals/plant-science>

2. Fuente de datos y scraping

Se utilizaron las librerías **chromote** y **rvest** para realizar web scraping sobre la página de listado de artículos de Frontiers in Plant Science, filtrada por el año 2025. La estrategia consistió en:

1. Abrir un navegador Chrome headless con **chromote** para renderizar el JavaScript de la página.
2. Pagar sobre la lista de artículos para recolectar las URLs de cada artículo.
3. Visitar cada artículo individualmente para extraer metadatos desde meta tags y elementos del DOM.

Limitaciones encontradas: - El sitio requiere JavaScript para cargar el contenido (no es HTML estático). - No todos los artículos muestran métricas de citas directamente en la página. - Se respetaron pausas entre solicitudes para no sobrecargar el servidor. - La métrica usada como equivalente a “descargas” es **Views** (vistas del artículo).

```
library(chromote)
library(rvest)
library(dplyr)
library(stringr)
library(DBI)
library(RSQLite)
library(lubridate)
```

```
BASE_URL <- "https://www.frontiersin.org/journals/plant-science/articles?publication-date=01%2F01%2F2025"
N_PAGINAS <- 10 # 10 páginas x 24 artículos = ~240 artículos
```

2.1 Recolección de URLs

```
b <- ChromoteSession$new()

todos_los_links <- c()

for (pag in 1:N_PAGINAS) {

  url_pag <- if (pag == 1) {
    BASE_URL
  } else {
```

```

    paste0(BASE_URL, "&page=", pag)
  }

  cat("Scrapeando página", pag, "...\\n")

  b$Page$navigate(url_pag)
  Sys.sleep(5)

  html <- b$Runtime$evaluate("document.documentElement.outerHTML")$result$value
  pagina <- read_html(html)

  links <- pagina |>
    html_elements("a") |>
    html_attr("href") |>
    grep("/articles/", x = _, value = TRUE)

  links_2025 <- links[grepl("fpls\\.2025\\.\"", links)]
  links_2025 <- unique(links_2025)

  cat("  ->", length(links_2025), "artículos encontrados\\n")
  todos_los_links <- c(todos_los_links, links_2025)
}

```

```

## Scrapeando página 1 ...
##   -> 24 artículos encontrados
## Scrapeando página 2 ...
##   -> 24 artículos encontrados
## Scrapeando página 3 ...
##   -> 24 artículos encontrados
## Scrapeando página 4 ...
##   -> 24 artículos encontrados
## Scrapeando página 5 ...
##   -> 24 artículos encontrados
## Scrapeando página 6 ...
##   -> 24 artículos encontrados
## Scrapeando página 7 ...
##   -> 24 artículos encontrados
## Scrapeando página 8 ...
##   -> 24 artículos encontrados
## Scrapeando página 9 ...
##   -> 24 artículos encontrados
## Scrapeando página 10 ...
##   -> 24 artículos encontrados

```

```

todos_los_links <- unique(todos_los_links)
cat("\\nTotal de URLs únicas recolectadas:", length(todos_los_links), "\\n")

```

```

##
## Total de URLs únicas recolectadas: 240

```

2.2 Extracción de metadatos por artículo

```

extraer_articulo <- function(b, url) {
  b$Page$navigate(url)

```

```

Sys.sleep(4)

html <- b$Runtime$evaluate("document.documentElement.outerHTML")$result$value
pag <- read_html(html)

# Título
titulo <- pag |> html_element("h1") |> html_text2() |> str_trim()

# DOI
doi_url <- paste0("https://doi.org/", str_extract(url, "10\\.3389/fpls\\.2025\\. [0-9]+"))

# Fecha desde meta tag
fecha_raw <- pag |> html_elements("meta[name='citation_online_date']") |> html_attr("content")
fecha_pub <- if (length(fecha_raw) > 0 && nchar(fecha_raw[1]) > 0) {
  as.character(as.Date(fecha_raw[1], format = "%Y/%m/%d"))
} else NA_character_

# Abstract desde meta tag
abstract <- pag |> html_elements("meta[name='citation_abstract']") |>
  html_attr("content") |> str_remove("^Abstract\\s*") |> str_trim()
if (length(abstract) == 0) abstract <- NA_character_

# Autores desde meta tags
autores <- pag |> html_elements("meta[name='citation_author']") |>
  html_attr("content") |> paste(collapse = "; ")
n_autores <- str_count(autores, ";") + 1
if (nchar(autores) == 0) { autores <- NA_character_; n_autores <- NA }

# Vistas y citas desde DOM
todos_textos <- pag |> html_elements("span, p, div") |> html_text2()

descargas <- str_extract(
  todos_textos[grepl("Views", todos_textos) & nchar(todos_textos) < 30] |> first(),
  "[0-9,]+"
) |> str_remove_all(",") |> as.integer()

citas <- str_extract(
  todos_textos[grepl("Citations", todos_textos) & nchar(todos_textos) < 30] |> first(),
  "[0-9,]+"
) |> str_remove_all(",") |> as.integer()

# Referencias
n_refs <- pag |> html_elements(".References li, [class*='reference'] li") |> length()
if (n_refs == 0) n_refs <- NA_integer_

list(
  journal_name = "Frontiers in Plant Science",
  title = titulo,
  publication_date = fecha_pub,
  year = 2025L,
  doi = doi_url,
  url = url,
  abstract = abstract,

```

```

    authors_raw      = autores,
    n_authors        = n_autores,
    citations         = citas,
    downloads         = descargas,
    n_references      = n_refs
  )
}

# Loop principal
lista_articulos <- list()

for (i in seq_along(todos_los_links)) {
  cat("Artículo", i, "de", length(todos_los_links), "\n")
  resultado <- tryCatch(
    extraer_articulo(b, todos_los_links[i]),
    error = function(e) { cat(" Error:", e$message, "\n"); NULL }
  )
  if (!is.null(resultado)) {
    lista_articulos[[length(lista_articulos) + 1]] <- resultado
  }
  Sys.sleep(1)
}

```

```

## Artículo 1 de 240
## Artículo 2 de 240
## Artículo 3 de 240
## Artículo 4 de 240
## Artículo 5 de 240
## Artículo 6 de 240
## Artículo 7 de 240
## Artículo 8 de 240
## Artículo 9 de 240
## Artículo 10 de 240
## Artículo 11 de 240
## Artículo 12 de 240
## Artículo 13 de 240
## Artículo 14 de 240
## Artículo 15 de 240
## Artículo 16 de 240
## Artículo 17 de 240
## Artículo 18 de 240
## Artículo 19 de 240
## Artículo 20 de 240
## Artículo 21 de 240
## Artículo 22 de 240
## Artículo 23 de 240
## Artículo 24 de 240
## Artículo 25 de 240
## Artículo 26 de 240
## Artículo 27 de 240
## Artículo 28 de 240
## Artículo 29 de 240
## Artículo 30 de 240
## Artículo 31 de 240

```

Artículo 32 de 240
Artículo 33 de 240
Artículo 34 de 240
Artículo 35 de 240
Artículo 36 de 240
Artículo 37 de 240
Artículo 38 de 240
Artículo 39 de 240
Artículo 40 de 240
Artículo 41 de 240
Artículo 42 de 240
Artículo 43 de 240
Artículo 44 de 240
Artículo 45 de 240
Artículo 46 de 240
Artículo 47 de 240
Artículo 48 de 240
Artículo 49 de 240
Artículo 50 de 240
Artículo 51 de 240
Artículo 52 de 240
Artículo 53 de 240
Artículo 54 de 240
Artículo 55 de 240
Artículo 56 de 240
Artículo 57 de 240
Artículo 58 de 240
Artículo 59 de 240
Artículo 60 de 240
Artículo 61 de 240
Artículo 62 de 240
Artículo 63 de 240
Artículo 64 de 240
Artículo 65 de 240
Artículo 66 de 240
Artículo 67 de 240
Artículo 68 de 240
Artículo 69 de 240
Artículo 70 de 240
Artículo 71 de 240
Artículo 72 de 240
Artículo 73 de 240
Artículo 74 de 240
Artículo 75 de 240
Artículo 76 de 240
Artículo 77 de 240
Artículo 78 de 240
Artículo 79 de 240
Artículo 80 de 240
Artículo 81 de 240
Artículo 82 de 240
Artículo 83 de 240
Artículo 84 de 240
Artículo 85 de 240

Artículo 86 de 240
Artículo 87 de 240
Artículo 88 de 240
Artículo 89 de 240
Artículo 90 de 240
Artículo 91 de 240
Artículo 92 de 240
Artículo 93 de 240
Artículo 94 de 240
Artículo 95 de 240
Artículo 96 de 240
Artículo 97 de 240
Artículo 98 de 240
Artículo 99 de 240
Artículo 100 de 240
Artículo 101 de 240
Artículo 102 de 240
Artículo 103 de 240
Artículo 104 de 240
Artículo 105 de 240
Artículo 106 de 240
Artículo 107 de 240
Artículo 108 de 240
Artículo 109 de 240
Artículo 110 de 240
Artículo 111 de 240
Artículo 112 de 240
Artículo 113 de 240
Artículo 114 de 240
Artículo 115 de 240
Artículo 116 de 240
Artículo 117 de 240
Artículo 118 de 240
Artículo 119 de 240
Artículo 120 de 240
Artículo 121 de 240
Artículo 122 de 240
Artículo 123 de 240
Artículo 124 de 240
Artículo 125 de 240
Artículo 126 de 240
Artículo 127 de 240
Artículo 128 de 240
Artículo 129 de 240
Artículo 130 de 240
Artículo 131 de 240
Artículo 132 de 240
Artículo 133 de 240
Artículo 134 de 240
Artículo 135 de 240
Artículo 136 de 240
Artículo 137 de 240
Artículo 138 de 240
Artículo 139 de 240

Artículo 140 de 240
Artículo 141 de 240
Artículo 142 de 240
Artículo 143 de 240
Artículo 144 de 240
Artículo 145 de 240
Artículo 146 de 240
Artículo 147 de 240
Artículo 148 de 240
Artículo 149 de 240
Artículo 150 de 240
Artículo 151 de 240
Artículo 152 de 240
Artículo 153 de 240
Artículo 154 de 240
Artículo 155 de 240
Artículo 156 de 240
Artículo 157 de 240
Artículo 158 de 240
Artículo 159 de 240
Artículo 160 de 240
Artículo 161 de 240
Artículo 162 de 240
Artículo 163 de 240
Artículo 164 de 240
Artículo 165 de 240
Artículo 166 de 240
Artículo 167 de 240
Artículo 168 de 240
Artículo 169 de 240
Artículo 170 de 240
Artículo 171 de 240
Artículo 172 de 240
Artículo 173 de 240
Artículo 174 de 240
Artículo 175 de 240
Artículo 176 de 240
Artículo 177 de 240
Artículo 178 de 240
Artículo 179 de 240
Artículo 180 de 240
Artículo 181 de 240
Artículo 182 de 240
Artículo 183 de 240
Artículo 184 de 240
Artículo 185 de 240
Artículo 186 de 240
Artículo 187 de 240
Artículo 188 de 240
Artículo 189 de 240
Artículo 190 de 240
Artículo 191 de 240
Artículo 192 de 240
Artículo 193 de 240

```
## Artículo 194 de 240
## Artículo 195 de 240
## Artículo 196 de 240
## Artículo 197 de 240
## Artículo 198 de 240
## Artículo 199 de 240
## Artículo 200 de 240
## Artículo 201 de 240
## Artículo 202 de 240
## Artículo 203 de 240
## Artículo 204 de 240
## Artículo 205 de 240
## Artículo 206 de 240
## Artículo 207 de 240
## Artículo 208 de 240
## Artículo 209 de 240
## Artículo 210 de 240
## Artículo 211 de 240
## Artículo 212 de 240
## Artículo 213 de 240
## Artículo 214 de 240
## Artículo 215 de 240
## Artículo 216 de 240
## Artículo 217 de 240
## Artículo 218 de 240
## Artículo 219 de 240
## Artículo 220 de 240
## Artículo 221 de 240
## Artículo 222 de 240
## Artículo 223 de 240
## Artículo 224 de 240
## Artículo 225 de 240
## Artículo 226 de 240
## Artículo 227 de 240
## Artículo 228 de 240
## Artículo 229 de 240
## Artículo 230 de 240
## Artículo 231 de 240
## Artículo 232 de 240
## Artículo 233 de 240
## Artículo 234 de 240
## Artículo 235 de 240
## Artículo 236 de 240
## Artículo 237 de 240
## Artículo 238 de 240
## Artículo 239 de 240
## Artículo 240 de 240
```

```
b$close()
```

```
## [1] TRUE
```

```
df_papers <- bind_rows(lista_articulos)
df_papers$paper_id <- seq_len(nrow(df_papers))
```



```
cat("\nArticulos recolectados:", nrow(df_papers), "\n")

##
## Articulos recolectados: 240

glimpse(df_papers)

## Rows: 240
## Columns: 13
## $ journal_name      <chr> "Frontiers in Plant Science", "Frontiers in Plant Sci-
## $ title              <chr> "CRISPR/Cas Technique: Revolutionizing Solanaceae Cro-
## $ publication_date   <chr> "2025-12-30", "2025-11-29", "2025-12-04", "2025-12-24-
## $ year              <int> 2025, 2025, 2025, 2025, 2025, 2025, 2025, 2025, 2025, ~
## $ doi               <chr> "https://doi.org/10.3389/fpls.2025.1709377", "https:/~
## $ url               <chr> "https://www.frontiersin.org/journals/plant-science/a-
## $ abstract          <chr> "Malnutrition and climate-induced stress remain major~
## $ authors_raw       <chr> "Thakur, Vandana ; Johar, VIshal ; BISHT, Vinita ; Vy~
## $ n_authors         <dbl> 9, 12, 1, 2, 8, 5, 9, 9, 7, 13, 10, 3, 9, 8, 6, 16, 1~
## $ citations         <int> NA, NA, NA, NA, 9, 3, 1, 1, 10, NA, NA, 1, 2, NA, NA, ~
## $ downloads         <int> 799, 18, 22, 181, 14, 16, 16, 15, 47, 15, 17, 14, 15, ~
## $ n_references      <int> NA, 218, 195, NA, 129, 154, 161, 176, 498, 177, 381, ~
## $ paper_id         <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16~
```

3. Clasificación temática

```
clasificar <- function(titulo, abstract) {
  texto <- tolower(paste(titulo, abstract, sep = " "))

  palabras_ia_gen <- c("generative", "large language model", "llm", "gpt",
    "diffusion model", "transformer", "chatgpt",
    "generative ai", "foundation model", "bert")

  palabras_ml <- c("machine learning", "deep learning", "neural network",
    "random forest", "classification", "clustering",
    "support vector", "convolutional", "cnn", "lstm",
    "gradient boosting", "xgboost", "prediction model")

  palabras_stat <- c("regression", "statistical", "bayesian", "anova",
    "multivariate", "principal component", "pca",
    "linear model", "mixed model", "correlation analysis",
    "hypothesis test", "variance")

  if (any(str_detect(texto, palabras_ia_gen))) return("IA Generativa")
  if (any(str_detect(texto, palabras_ml))) return("Machine Learning")
  if (any(str_detect(texto, palabras_stat))) return("Estadística")
  return("Otros")
}

df_papers <- df_papers |>
  mutate(topic_label = mapapply(clasificar, title, abstract))

table(df_papers$topic_label)

##
```

##	Estadística	IA Generativa	Machine Learning	Otros
##	31	13	40	156

4. Construcción de la base de datos SQLite

```
con <- dbConnect(SQLite(), "frontiers_plant_science_2025.sqlite")
```

```
dbExecute(con, "DROP TABLE IF EXISTS papers")
```

```
## [1] 0
```

```
dbExecute(con, "
CREATE TABLE papers (
  paper_id      INTEGER PRIMARY KEY,
  journal_name  TEXT,
  title         TEXT,
  publication_date TEXT,
  year         INTEGER,
  doi          TEXT,
  url          TEXT,
  abstract     TEXT,
  authors_raw  TEXT,
  n_authors    INTEGER,
  citations    INTEGER,
  downloads    INTEGER,
  n_references  INTEGER,
  topic_label  TEXT
)
")
```

```
## [1] 0
```

```
dbWriteTable(con, "papers", df_papers |> select(
  paper_id, journal_name, title, publication_date, year,
  doi, url, abstract, authors_raw, n_authors,
  citations, downloads, n_references, topic_label
), append = TRUE)
```

```
cat("Registros insertados:", dbGetQuery(con, "SELECT COUNT(*) as n FROM papers")$n, "\n")
```

```
## Registros insertados: 240
```

5. Consultas SQL

```
# 1. Promedio de autores por paper
```

```
dbGetQuery(con, "SELECT ROUND(AVG(n_authors), 2) AS promedio_autores FROM papers")
```

```
## promedio_autores
```

```
## 1 7.16
```

```
# 2. Artículos relacionados con Machine Learning
```

```
dbGetQuery(con, "SELECT COUNT(*) AS n_machine_learning FROM papers WHERE topic_label = 'Machine Learning'")
```

```
## n_machine_learning
```

```
## 1 40
```

```

# 3. Artículos relacionados con IA Generativa
dbGetQuery(con, "SELECT COUNT(*) AS n_ia_generativa FROM papers WHERE topic_label = 'IA Generativa'")

##      n_ia_generativa
## 1                  13

# 4. Artículos relacionados con Estadística
dbGetQuery(con, "SELECT COUNT(*) AS n_estadistica FROM papers WHERE topic_label = 'Estadística'")

##      n_estadistica
## 1                  31

# 5. Total de vistas (equivalente a descargas) en 2025
dbGetQuery(con, "SELECT SUM(downloads) AS total_vistas FROM papers WHERE year = 2025")

##      total_vistas
## 1              26780

# 6. Promedio de referencias por artículo
dbGetQuery(con, "SELECT ROUND(AVG(n_references), 2) AS promedio_referencias FROM papers")

##      promedio_referencias
## 1                  224.51

# 7. Referencia más repetida - no disponible sin tabla auxiliar
cat("Variable no disponible: Frontiers no expone la lista de referencias en HTML estructurado. Ver sección 7.1")

## Variable no disponible: Frontiers no expone la lista de referencias en HTML estructurado. Ver sección 7.1

# 8. Promedio de citas por artículo
dbGetQuery(con, "SELECT ROUND(AVG(citations), 2) AS promedio_citas FROM papers")

##      promedio_citas
## 1                  1.72

# 9. Paper con más citas
dbGetQuery(con, "SELECT title, citations FROM papers ORDER BY citations DESC LIMIT 1")

##                                     title
## 1 [Physiological, biochemical and molecular signaling basis of cold stress tolerance in plants]
##      citations
## 1              10

# 10. Paper de ML, IA Gen o Estadística con más citas
dbGetQuery(con, "
  SELECT title, topic_label, citations
  FROM papers
  WHERE topic_label IN ('Machine Learning', 'IA Generativa', 'Estadística')
  ORDER BY citations DESC
  LIMIT 1
")

##                                     title
## 1 [An ensemble heterogeneous transformer model for an effective diagnosis of multiple plant diseases]
##      topic_label citations
## 1 IA Generativa      7

# 11. Paper de ML, IA Gen o Estadística con más descargas
dbGetQuery(con, "
  SELECT title, topic_label, downloads

```

```
FROM papers
WHERE topic_label IN ('Machine Learning', 'IA Generativa', 'Estadística')
ORDER BY downloads DESC
LIMIT 1
")
```

```
##                                                                 title
## 1 [Proximal hyperspectral detection of rice and weed: characterization and discriminant analysis]
##      topic_label downloads
## 1 Machine Learning      987
```

6. Hallazgos

```
cat("Distribución temática:\n")
```

```
## Distribución temática:
```

```
print(table(df_papers$topic_label))
```

```
##
##      Estadística      IA Generativa Machine Learning      Otros
##              31              13              40              156
```

```
cat("\nTop 5 artículos por vistas:\n")
```

```
##
## Top 5 artículos por vistas:
```

```
df_papers |>
  arrange(desc(downloads)) |>
  select(title, downloads, topic_label) |>
  head(5) |>
  print()
```

```
## # A tibble: 5 x 3
##   title                                downloads topic_label
##   <chr>                                <int> <chr>
## 1 [Proximal hyperspectral detection of rice and weed: cha~    987 Machine Le~
## 2 [Editorial: Mechanisms behind stress tolerance induced ~    983 IA Generat~
## 3 [Functional characterization of EjAP1-like1 reveals its~    974 Otros
## 4 [Leaf color as an indicator of the accumulation pattern~    974 Estadística
## 5 [Editorial: Green growth: innovations in plant science ~    971 Otros
```

```
cat("\nTop 5 artículos por citas:\n")
```

```
##
## Top 5 artículos por citas:
```

```
df_papers |>
  arrange(desc(citations)) |>
  select(title, citations, topic_label) |>
  head(5) |>
  print()
```

```
## # A tibble: 5 x 3
##   title                                citations topic_label
##   <chr>                                <int> <chr>
## 1 [Physiological, biochemical and molecular signaling bas~     10 Otros
```

## 2 [Gradient-guided boundary-aware selective scanning with~	9 Otros
## 3 [Reactive oxygen species: balancing agents in plants]	7 Otros
## 4 [An ensemble heterogeneous transformer model for an eff~	7 IA Generat~
## 5 [From data to decisions: a paradigm shift in fruit agri~	4 Machine Le~

7. Limitaciones

- **JavaScript requerido:** Frontiers in Plant Science carga su contenido dinámicamente, lo que obligó a usar `chromote` (navegador headless) en lugar de scraping HTML estático.
- **Citas:** Frontiers no muestra citas en todos los artículos. Los valores faltantes se registran como `NULL`.
- **Métrica de descargas:** Se usaron **Views** (vistas) como métrica equivalente a descargas, ya que es la única métrica de uso disponible públicamente en Frontiers.
- **Referencias individuales:** No fue posible extraer la lista de referencias individuales ya que Frontiers no las expone en HTML estructurado. La columna `n_references` contiene el conteo total cuando está disponible.
- **Muestra:** Se recolectaron 240 artículos de los 3.243 publicados en 2025 (primeras 10 páginas).

8. Conclusión

Se construyó una base de datos SQLite con 240 artículos de 2025 de Frontiers in Plant Science mediante web scraping con `chromote` y `rvest`. La mayoría de los artículos corresponden a la categoría “Otros” (biología vegetal tradicional), con una minoría aplicando técnicas de Machine Learning o estadística avanzada. Las métricas de vistas estuvieron disponibles parcialmente, mientras que las citas fueron escasas dado que muchos artículos son recientes.

```
dbDisconnect(con)
```